Not: Proje geliştirilirken; araştırma, kodlama, analiz ve raporlama süreçlerinde yapay zeka araçları kullanılmıştır.

Görev 4 | Yabancı Ot (Weed) Tespiti ve Konumlandırma

Bu çalışma kapsamında **Görev 4: Yabancı Ot (Weed) Tespiti ve Konumlandırma** problemi seçilmiştir. Bu görevi seçmemdeki asıl neden; DRONEQUBE'un drone platformları üzerindeki projelerine doğrudan entegre edilebilecek, sahadaki pratik ihtiyaca tam anlamıyla karşılık veren bir problemi ele almak istememdi. Yani kısaca DRONEQUBE'nin geliştridiği fikirelre en uygun çalışmanın bu olacağına inanmamdan ve bulduğum kaynak ve veri setinin de bunu desteklediğini görünce bu konuda çalışma yapmak istedim.

Literatürü incelediğimde WeedsGalore, WeedMap, PhenoBench, CoFly-WeedDB ve Weedy Rice Dataset gibi kaynaklar öne çıktı. Ancak bunlar arasında özellikle 2025 tarihli "*WeedsGalore: A Multispectral and Multitemporal UAV-based Dataset for Crop and Weed Segmentation in Agricultural Maize Fields*" çalışması, doğrudan uygulanabilirliği ile dikkatimi çekti. Diğer veri setlerinin kimisi şeker pancarına odaklanırken (PhenoBench), kimisi daha çok semantik haritalamaya yönelik kalıyordu (WeedMap). WeedsGalore ise bu projede temel kaynak olarak belirlenmiştir.

Neden WeedsGalore Veri Seti?

WeedsGalore veri setini tercih etmemin başlıca nedeni, görev dokümanında belirtilen gereksinimleri fazlasıyla karşılamasının yanı sıra DRONEQUBE firmasının vizyonu ile doğrudan örtüşmesidir. Mısır bitkileri ile yabancı otları aynı sahnede barındıran bu veri seti, otların hem semantik (piksel bazlı) hem de nesne (instance) seviyesinde etiketlerini sunmaktadır. Bu sayede yalnızca "bu bölgede yabancı ot var" şeklinde genel bir analiz yapmak yerine, tekil otların veya ot kümelerinin tespit edilmesi, konumlandırılması ve alan hesaplarının gerçekleştirilmesi mümkün olmaktadır.

Veri setini cazip kılan bir diğer önemli özellik ise zamansal (multitemporal) çeşitliliğe sahip olmasıdır. Görüntülerin Mayıs ve Haziran aylarında, farklı büyüme evrelerinde elde edilmiş olması;, farklı yoğunluk ve gelişim seviyelerindeki tarla koşullarına karşı dayanıklılığını test etme imkanı sunmaktadır. Ayrıca bu yapı, zaman içinde yabancı ot yoğunluğunun nasıl değiştiğini analiz etmeye ve belirli dönemlerdeki artışların izlenmesine olanak tanımaktadır.

Not: Makalede görüntülerin gerçek dünya koordinatlarıyla ilişkili olduğundan bahsedilmesine rağmen, veri setinin detaylı incelenmesi sonucunda tekil görüntüler için doğrudan kullanılabilir GPS (lat/lon) bilgisine ulaşılamamıştır. Bu nedenle çalışmada yalnızca görüntü içi (lokal) koordinatlar üretilebilmektedir.

WeedsGalore makalesine göre, yaklaşık 5 m uçuş yüksekliğinde elde edilen görüntüler için GSD değeri yaklaşık **2.5 mm/pixel**'dir ve görüntüler **600×600 merkez crop** şeklindedir. Bu doğrultuda, pikselden metreye dönüşüm lokal ölçekte anlamlı ve uygulanabilir bir yaklaşım sunmaktadır.

Makalenin ve Veri Setinin Özeti

İncelediğim WeedsGalore makalesi, 2025 yılında IEEE/CVF Winter Conference on Applications of Computer Vision (WACV) 2025 kapsamında yayımlanmış oldukça güncel bir çalışmadır. Çalışma, Almanya'nın Potsdam bölgesinde yer alan gerçek bir mısır tarlasında toplanan verileri içermektedir. Veri toplama sürecinde DJI Phantom 4 Multispectral drone kullanılmış ve yaklaşık 5 metre uçuş yüksekliğinde, yüksek çözünürlüklü görüntüler elde edilmiştir

Makale sadece veriyi paylaşmakla kalmayıp DeepLabv3+ ve MaskFormer gibi mimarilerle temel referans sonuçlar (baseline) sunmasıdır. Veri setine makalenin yönlendirdiği açık kaynaklı resmi GitHub deposu (**GFZ/weedsgalore**) üzerinden eriştim.

Makaledeki Yöntem ve Kendi YOLO Tercihimin Karşılaştırması

Bu belgeyi hazırlarken, orijinal makaledeki segmentasyon yaklaşımı ile benim projede tercih ettiğim YOLO tabanlı yöntemin neden farklılaştığını ve bu tercihin arkasındaki mühendislik gerekçelerini net bir şekilde ortaya koymak istedim.

Makaledeki yaklaşımda, yabancı ot tespiti problemi DeepLabv3+ ve MaskFormer gibi semantik ve instance segmentasyon modelleriyle ele alınmaktadır. Bu modellerin en güçlü yanı, piksel seviyesinde oldukça hassas sonuçlar üretebilmeleridir. Ayrıca yazarlar, MC Dropout gibi yöntemlerle modelin hangi bölgelerde kararsız olduğunu analiz ederek belirsizlik haritaları oluşturmuşlardır.

Ancak bu yaklaşımın önemli bir dezavantajı da bulunmaktadır: hesaplama maliyeti. Piksel bazlı segmentasyon, özellikle yüksek çözünürlüklü multispektral drone verilerinde ciddi donanım ihtiyacı ve uzun işlem süreleri gerektirir. Üstelik MC Dropout gibi teknikler, tek bir görüntü için birden fazla işlem yapılmasını zorunlu kılar. Bu durum, yöntemi akademik çalışmalar ve çevrimdışı analizler için çok güçlü kılarken; uçuş sırasında anlık karar vermesi gereken, sınırlı işlem gücüne sahip bir drone sistemi için pratik olmaktan uzaklaştırmaktadır.

Bu noktada benim tercih ettiğim yaklaşım, YOLO tabanlı (segmentasyon destekli) bir model oldu. Bunun temel nedeni, gerçek dünya uygulamalarında en kritik dengenin hız ve doğruluk arasında kurulması gerektiğine inanmamdır. Bir drone sistemi için yalnızca doğru sonuç üretmek yeterli değildir; aynı zamanda bu sonucu hızlı ve düşük kaynak tüketimiyle elde edebilmek de gerekir.

YOLO mimarisi, tek aşamalı yapısı sayesinde hem nesne tespiti hem de segmentasyonu tek bir işlem akışında gerçekleştirebilir. Bu da sistemi daha hafif, daha hızlı ve sahada uygulanabilir hale getirir. Sonuç olarak model; “ot nerede?” sorusunun yanı sıra “ne kadar alan kaplıyor?” sorusuna da yeterli doğrulukta ve çok daha kısa sürede cevap verebilmektedir.

Buna ek olarak, ilgili veri seti ve makale kapsamında zaten kapsamlı bir çalışma gerçekleştirilmiş ve tüm kaynaklar açık şekilde paylaşılmıştır. Bu durum, aynı yöntemi tekrar etmek yerine farklı bir yaklaşım deneme ve sonuçları karşılaştırma fırsatı sunmuştur. Bu nedenle YOLO tabanlı bir yöntem tercih ederek, alternatif bir çözümün sahadaki performansını gözlemlemek ve mevcut çalışmalarla kıyaslama yapabilmek hedeflenmiştir.

YOLO Modellerinin Karşılaştırılması ve Seçilen Nihai Mimari

Bu çalışma kapsamında, WeedsGalore veri seti üzerinde eğittiğim dokuz farklı YOLO tabanlı segmentasyon modelinin performanslarını detaylı olarak analiz ettim. Eğitim süreçlerinde izlenen ortak adımları, uygulanan veri artırma (data augmentation) yöntemlerini ve elde edilen sonuçları karşılaştırmalı olarak değerlendirdim.

Bu sürecin temel amacı, yalnızca metrikler açısından en yüksek skoru elde eden modeli seçmek değil; aynı zamanda drone üzerinde gerçek zamanlı çalışabilecek, dengeli ve kararlı bir mimariyi belirlemekti. Karşılaştırma kapsamında değerlendirilen modeller şunlardır: YOLOv8s-seg, YOLOv8m-seg, YOLOv8l-seg, YOLOv11s-seg, YOLOv11m-seg, YOLOv11l-seg, YOLO26s-seg, YOLO26m-seg ve YOLO26l-seg. Karar sürecinde temel değerlendirme kriterlerim; model doğruluğu, hız ve sahadaki uygulanabilirlik dengesi olmuştur.

Veri Hazırlama ve Ön İşleme

Tüm modelleri aynı veri hazırlama mantığıyla eğittim. WeedsGalore veri setindeki R (Kırmızı), G (Yeşil) ve B (Mavi) bantlarını birleştirerek standart RGB görüntüler ürettim. Veri setinin kendi içindeki "train, val, test" (eğitim, doğrulama, test) ayrımına sadık kaldım.

Etiketleme tarafında ise bir sadeleştirmeye gittim: Mısır bitkisini **crop** (kültür bitkisi), diğer tüm yabancı ot türlerini ise tek bir çatı altında **weed** (yabancı ot) olarak birleştirdim. Böylece görevi, tam da sahadaki karar mekanizmasının ihtiyacı olan "iki sınıflı net bir segmentasyon" problemine dönüştürdüm bunun diğer bir sebebide bazı yabancı ot türlerinde veri azlığı sorununu azaltarak sınıfları dengelemekti. Ayrıca orijinal verideki maskeleri doğrudan YOLO'nun istediği formatına çevirerek tüm modelleri aynı standart etiketler üzerinden test ettim.

Ortak Eğitim Ayarları

Testin tutarlılığını korumak için çekirdek eğitim ayarlarını sabit tuttum. Tüm modeller; 1024 piksel giriş boyutu, 200 epoch, 50 patience (erken durdurma), AdamW optimizer, 0.001 başlangıç öğrenme oranı ve 0.0005 weight decay ile eğitildi.

Modellerin boyutları birbirinden çok farklı olduğu için GPU belleğini verimli kullanmak adına *batch size* (parti boyutu) değerini modele göre ayarlamak durumunda kaldım. Bunun haricindeki tüm parametreler tamamen aynıydı.

Veri Artırma (Data Augmentation) Tercihleri

Drone uçuşlarında kameranın yönü, güneşin açısı, çekim irtifası (ölçek) sürekli değiştiği için modelin ezberlemesini önlemek adına güçlü veri artırma teknikleri kullandım. HSV renk uzayında oynamalar, döndürme (rotation), çeviri, ölçekleme, yatay/dikey çevirme (flip), mosaic, mixup ve copy-paste gibi tekniklerle modeli her türlü zorlu tarla koşuluna hazırladım. Amacım, modelin sadece eğitim setindeki o pırıl pırıl günlere değil, sahadaki gölgeli ve ters ışıklı zorlu şartlara da dayanıklı olmasını sağlamaktı.

Dokuz Modelin Karşılaştırılması

Genel performansı görmek için **Mask mAP50**, daha detaylı segmentasyon başarısını değerlendirmek için **Mask mAP50-95** ve sahada kritik olan yabancı otları kaçırmamak adına **Weed Recall** metriklerine göre karşılaştırılmıştır.

Sıra	Model	Parametre	Eğitim S.	Box mAP50	Mask mAP50	Mask mAP50-95	Weed Recall
1	YOLOv8l-seg	**45.9M**	17.7 dk	**0.9011**	**0.8409**	0.2970	**0.7783**
2	YOLO26m-seg	23.5M	14.5 dk	0.8594	0.8161	**0.3029**	0.7186
3	YOLOv8m-seg	27.2M	12.4 dk	0.8893	0.8137	0.2777	0.7476
4	YOLOv11s-seg	10.1M	9.7 dk	0.8865	0.8107	0.2741	0.7151
5	YOLO26l-seg	27.9M	**20.3 dk**	0.8745	0.8095	0.2855	0.7356
6	YOLO26s-seg	10.4M	10.0 dk	0.8516	0.8051	0.2929	0.7367
7	YOLOv11l-seg	27.6M	13.8 dk	0.8767	0.8043	0.2778	0.6888
8	YOLOv11m-seg	22.3M	10.1 dk	0.8817	0.7963	0.2548	0.7029
9	YOLOv8s-seg	11.8M	6.8 dk	0.8742	0.7870	0.2662	0.7031

Sonuç tablosuna baktığımızda **YOLOv8l-seg** modelinin Mask mAP50, Box mAP50 ve Weed Recall başlıklarında dengeyi kurduğunu görüyoruz.

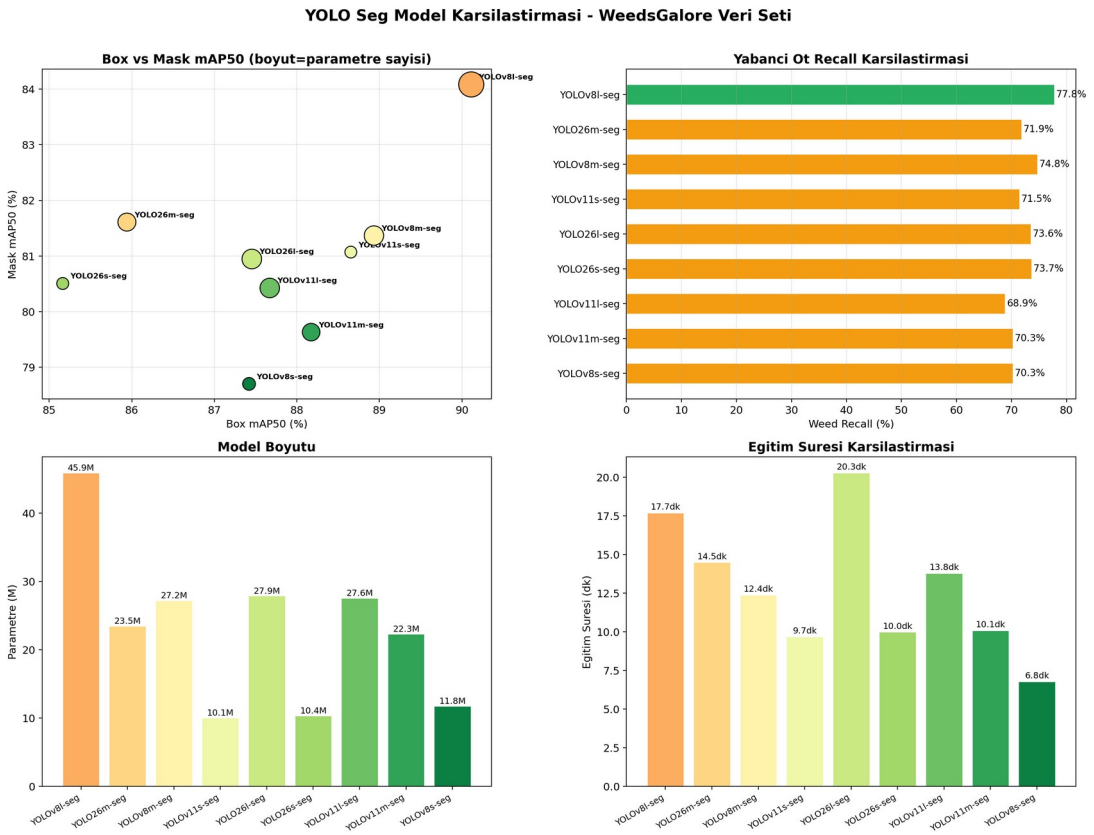

Grafik 1: Dokuz farklı YOLO modelinin karşılaştırılmaları

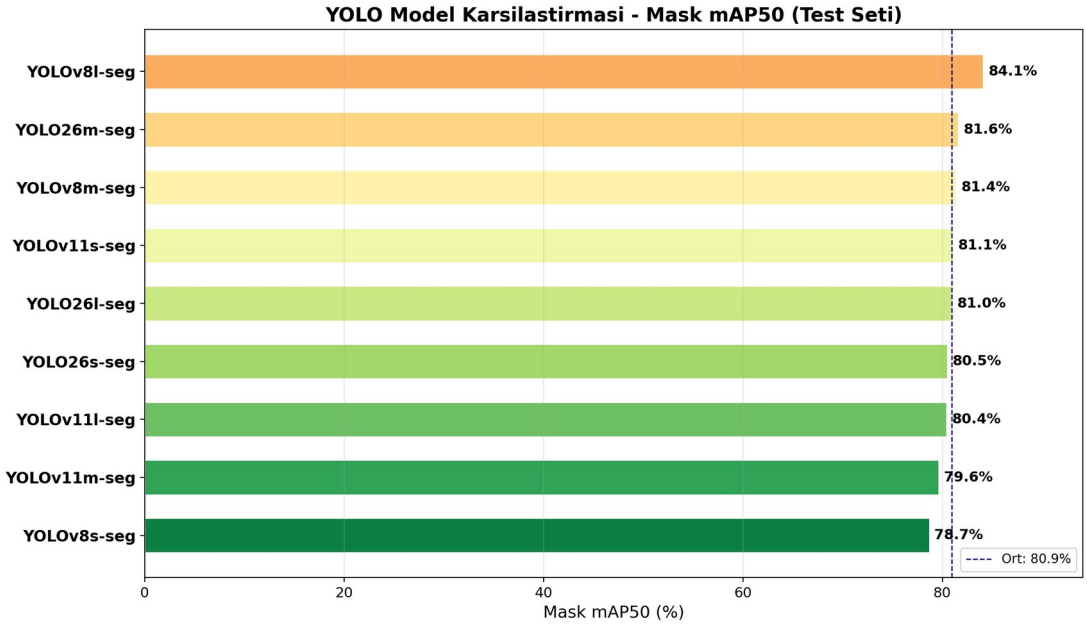

Grafik 2: Modellerin mAP performans karşılaştırmaları

Neden YOLOv8l-seg Mimarisini Seçtim?

Tüm bu testlerin sonucunda projeye **YOLOv8l-seg** modeli ile devam etme kararı aldım. Bu kararın temel nedeni; modelin diğer seçeneklere kıyasla **Box mAP50**, **Mask mAP50** ve **Yabancı Ot Recall** metriklerinde en yüksek değerleri birlikte sunarak hem doğruluk hem de sahadaki kritik ihtiyaçlar açısından en dengeli performansı göstermesidir.

Seçilen Modelin Teknik Özeti ve Çalışma Düzeni

- **Nihai Model:** YOLOv8l-seg
- **Parametre Sayısı:** 45.9 Milyon
- **Eğitim Süresi:** 17.7 Dakika (Colab/GPU)
- **Box mAP50 (Nesne Tespiti):** 0.9011
- **Mask mAP50 (Segmentasyon):** 0.8409
- **Weed Recall (Ot Yakalama):** 0.7783

Eğitim Sonuçları ve Kayıp (Loss) Eğrileri

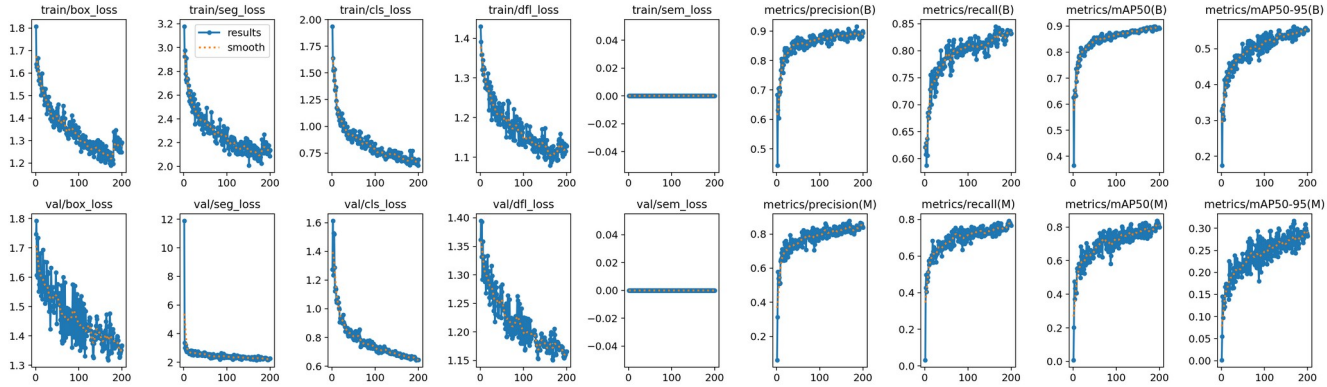

Grafik 3: Eğitim ve doğrulama süreçlerindeki metrikler.

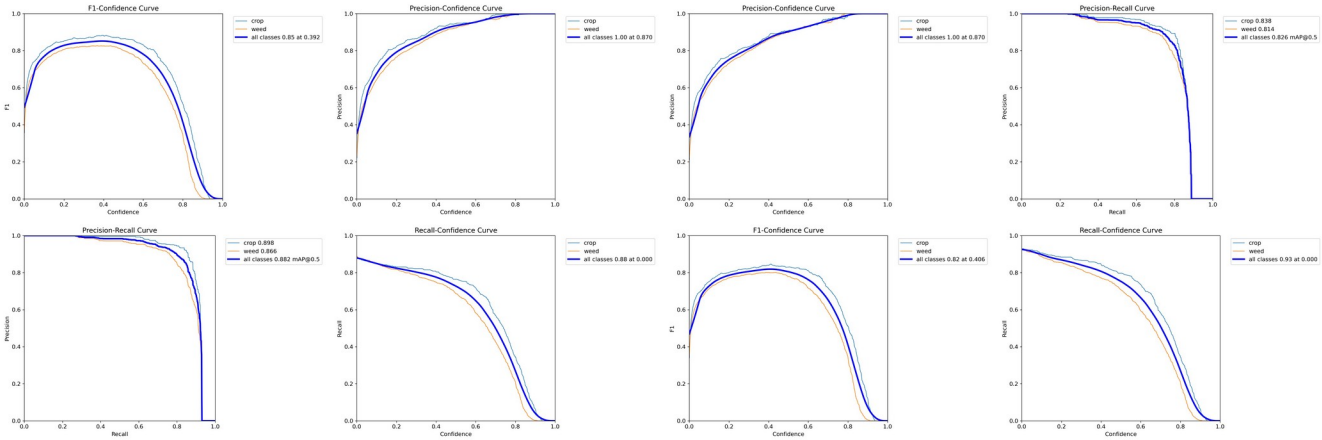

Grafik 4: Boxpr ve Maskf1 değerlerinin eğitim epochları boyunca gelişimi.

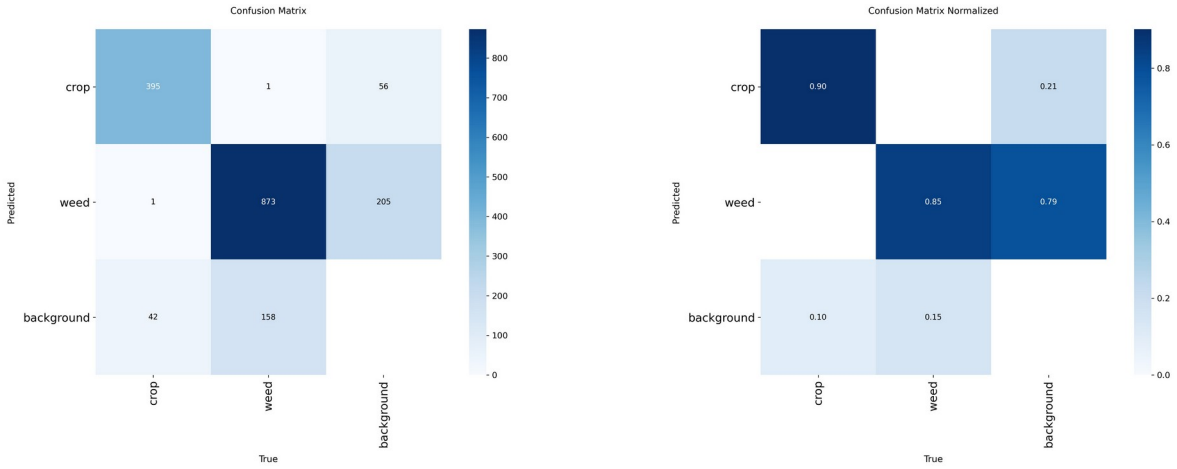

Grafik 5: Modelin eğitim sürecindeki Precision-Recall (Hassasiyet-Duyarlılık) analizleri.

Test Sonuçları ve Genel Başarı

YOLOv8l-seg modelini daha önce hiç görmediği *26* görüntülük test seti (toplam 58.5 m² tarla alanı) üzerinde sınadım. Bu testlerde; kültür bitkisi için (crop IoU) **0.5857**, yabancı ot için (weed IoU) **0.4189** ve ortalama (mIoU) **0.5023** değerlerini elde ettim.

Model, sahadaki gerçek 247 mısır bitkisine karşılık 287 tahmin üretirken; 923 gerçek yabancı ota karşılık 1167 ot tahmini üretti.

Zamansal ve Mekansal Gözlemler

Sonuçları tarihlere göre incelediğimde, yabancı ot yoğunluğunun zamanla belirgin şekilde arttığı görülmektedir. Gerçek etiketlere göre 25 Mayıs'ta toplam 9 yabancı ot bulunurken, bu sayı 30 Mayıs'ta 206'ya, 6 Haziran'da 546'ya ve 15 Haziran'da 162'ye ulaşmıştır. 15 Haziran'da yalnızca 2 görüntü bulunduğu için toplam sayı daha düşük görünse de, görüntü başına ortalama yabancı ot sayısı en yüksek seviyededir.

Alan bazında da benzer bir artış vardır. Yabancı ot yoğunluğu 25 Mayıs'ta yaklaşık %0.03 iken, 30 Mayıs'ta %0.97'ye, 6 Haziran'da %6.64'e ve 15 Haziran'da %34.74'e yükselmiştir. Model tahminlerinde de bu eğilim korunmuş ve 15 Haziran için yaklaşık %35.27 yabancı ot yoğunluğu hesaplanmıştır.

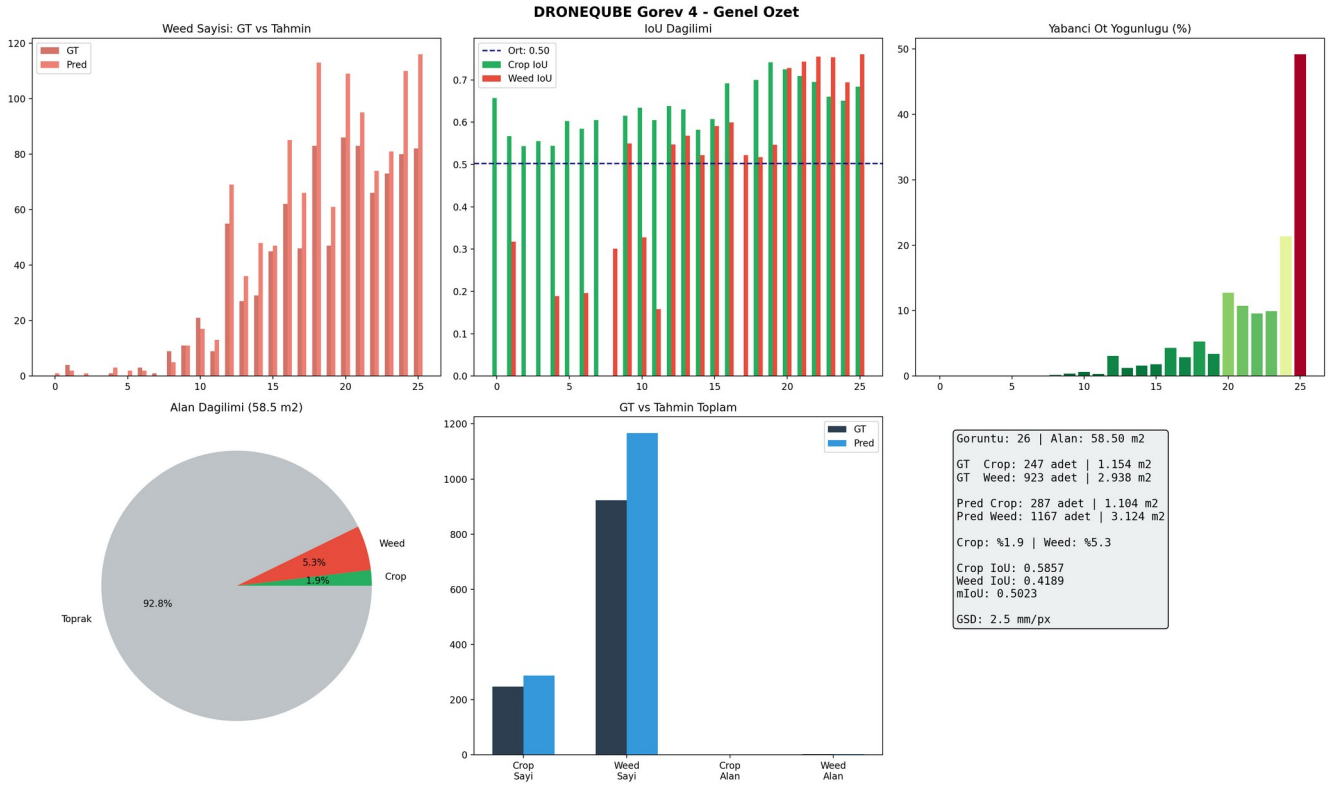

Grafik 6: Tespiti Raporu.

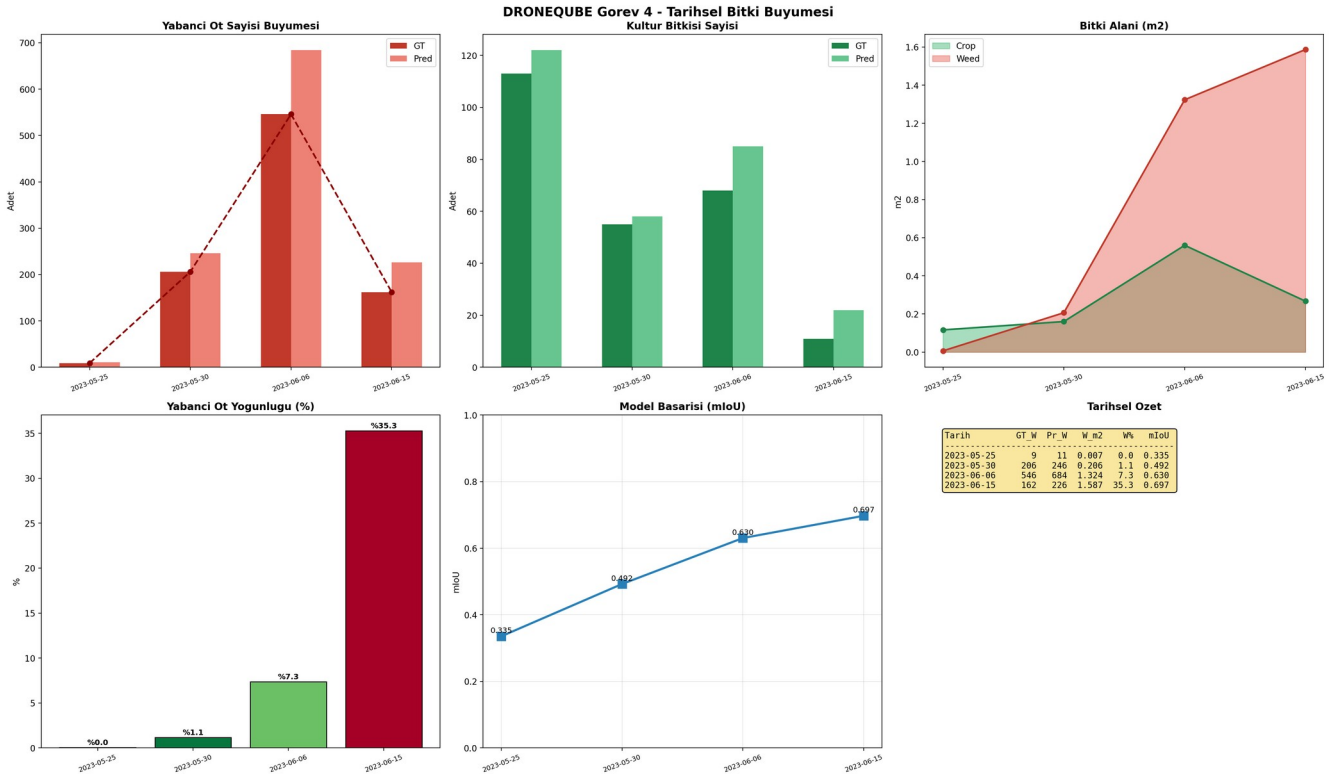

Grafik 7: Tarlada kapladığı alan ve yoğunluk yüzdelerinin zamansal analizi.

Çıktı Görselleri Üzerinden Değerlendirme

Modelin görsel çıktаларын incelediğimde, özellikle yabancı ot yoğunluğunun arttığı 6 Haziran ve 15 Haziran tarihli sahalarda daha tutarlı ve anlamlı sonuçlar ürettiğini gözlemledim. Yoğunluk arttıkça modelin nesneleri ayırma ve sınırlarını belirleme performansının da iyileştiği görülmektedir.

Bunun iyi bir örneği, **2023-06-15_0735.png** görüntüsüdür. Bu sahnede model; **17 adet crop** ve **116 adet weed** tespit etmiştir. Tahmin edilen yabancı ot alanı **1.1069 m²**, yoğunluk ise **%49.19** olarak hesaplanmıştır .

Ayrıca bu görüntüde yabancı ot IoU değeri yaklaşık **0.76** seviyesindedir, bu da yoğun ve karmaşık bir sahnede modelin segmentasyon başarısının oldukça iyi olduğunu göstermektedir.

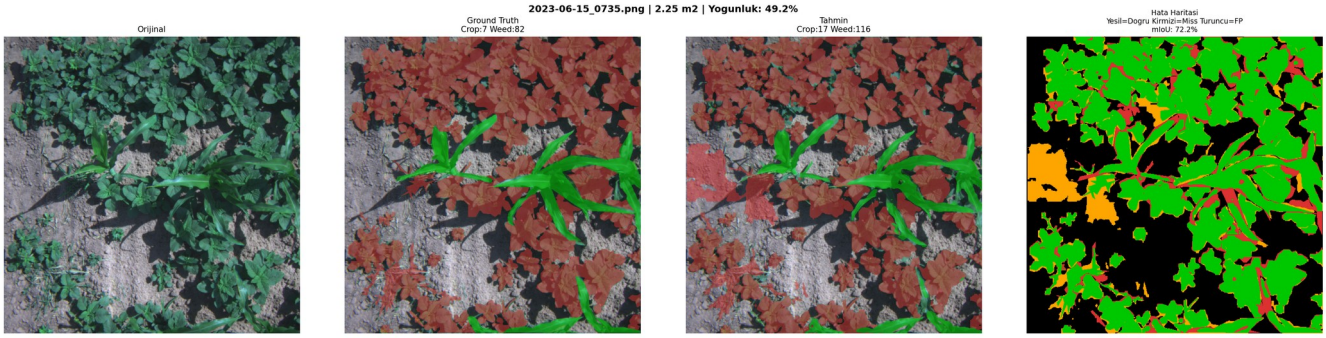

Görsel 1: Segmentasyon Sonucu.

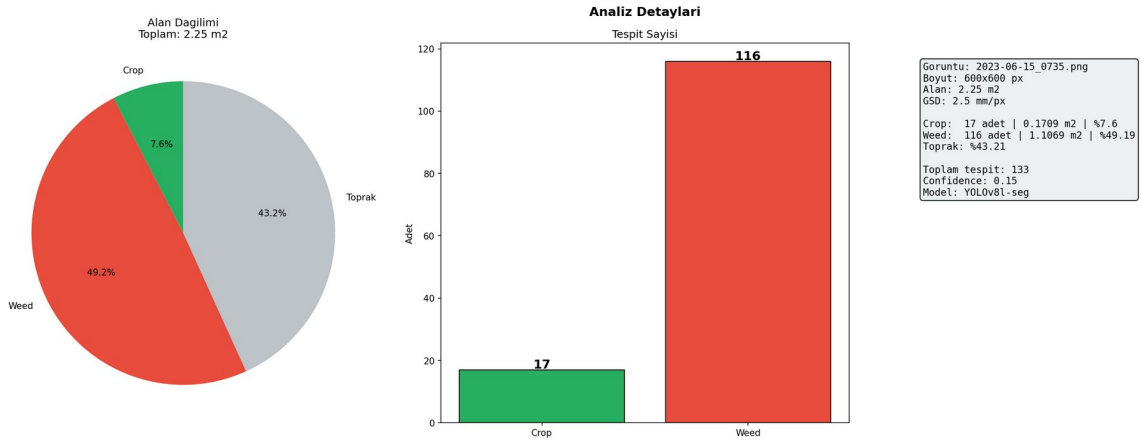

Görsel 3: Goruntu Analiz sonucu.

Görsel 4: Koordinat Haritasi.

Modelin Gerçek Eksi Yönleri ve Teknik Sınırlamalar

- **Instance vs Semantic Uyuşmazlığı ve Bilgi Kaybı:** train.py dosyasında piksel tabanlı orijinal segmentasyon maskeleri cv2.approxPolyDP metoduyla poligonlara dönüştürülerek YOLO'ya beslenmiştir. Yoğun yabancı ot bölgelerinde poligonizasyon, bitki sınır detaylarının kaybolmasına ve IoU performansının yapay olarak düşmesine yol açmaktadır. Benzer gözlem 2. çalışmada da karşılaşıldı bu sebebden daolyı 2. çalışmada yolo yerine bu yapıya daha uyunun olan DeepLabv3+ modeli kullanılarak ilerlenmiştri burda çalışmanın başarıısnda gözle görülür artış yapmıştır.
- **Georeferencing (Gerçek Konumlandırma) Eksikliği:** Görev 4 beklentisi doğrultusunda çıktı üretilse de, koordinatlar sadece görüntü içi lokal (X, Y metre) verilere dayanmaktadır. parsel_yogunluk.csv dosyasında açıkça "*gerçek dünya parsel georeference özeti değildir*" notu yer almaktadır. WGS84 / UTM gibi küresel bir koordinat sisteminin entegre edilmemesi büyük bir eksikliktir. Bunun en temel sebebi veri setinde tam görsellerin konumlarının iletilmemesi bu sorunu uygun olan 2. çalışma ile giderilmiştir.

Zor Örnekler İçin Hata Analizi (6 ve 15 Haziran Verileri Üzerinden)

Görev 4'te belirtilen "*Kültür bitkisi ile yabancı otun karıştığı zor örnekler için hata analizi yapılması*" kriteri uyarınca, geç büyüme evrelerini temsil eden Haziran ayı verileri incelenmiştir.

- **Erken Evre (25 Mayıs):** Bitkiler ayrık ve küçüktür (Örn: 2023-05-25_0109.png, yabancı ot yoğunluğu %0.03). Model bu evrede oldukça başarılıdır, IoU oranları yüksektir.
- **Zorlu Geç Evre (6 ve 15 Haziran):** Bitkiler birbirine karışmış ve alanın büyük kısmını kaplamıştır.

- **Görsel 1 (**2023-06-15_0735.png**):** Bu görüntüde Ground Truth (Gerçek) yabancı ot sayısı **82** iken, model **116** adet tespit yapmıştır (Yanlış Pozitif patlaması). ekimde ise gerçekte **7** bitki varken model **17** adet tespit etmiştir. Görüntüdeki toplam yabancı ot alanı %49.19'dur.
- **Görsel 2 (**2023-06-15_0169.png**):** Yabancı ot tespit sayısı **80** (GT) yerine **110** (Pred) olarak ölçülmüştür.
- Haziran aylarında bitki gölgelenmeleri ve yaprak örtüşmeleri maksimuma çıkmaktadır. Tahminimce YOLOv8l-seg modeli, birleşik devasa ot yığınlarını tek bir patch olarak maskelemekte zorlanıp, bu kütleyi gerçekte olmayan küçük parçalara bölmektedir. Bu durum, "ot alanı" hesabını (m2) çok bozmasa da, "ot sayımı" (count) açısından örneklerde de görüldüğü gibi hatalara sebep olmaktadır. Yani otlar seyrekken yolo modeli başarılı sayım ve segmentasyon yapabiliyorken bitki örtüsü büyüp kapladığı alan artıp bitkiler iç içe geçmeye başlayınca hatalı tespitler ve hatalı sayımlar artmaktadır.

Genel Başarı Değerlendirmesi

Genel tabloya bakıldığında, **YOLOv8l-seg** mimarisinin Görev 4 (Yabancı Ot Tespiti ve Konumlandırma) kapsamında başarılı ve dengeli bir performans sergilediği görülmektedir. Model, yalnızca eğitim metriklerinde değil; farklı yoğunluk seviyelerine sahip test sahalarında da tutarlı ve sahada kullanılabilir çıktılar üretmiştir. Özellikle **yabancı ot yakalama oranı (recall)** ve karmaşık sahnelerde ürettiği segmentasyon maskelerinin kalitesi, modelin gerçek dünya uygulamalarına uygun olduğunu göstermektedir.

Bu çalışmada elde edilen sonuçlara göre modelin **ortalama mIoU değeri yaklaşık %50**, en iyi senaryolarda ise **%70 seviyesine** ulaşmaktadır. Buna karşılık, DeepLabv3+ ve MaskFormer tabanlı makale yaklaşımında yaklaşık **%82 mIoU** seviyesine ulaşılmıştır . Bu fark, kullanılan mimarilerden ve veri ön işleme farklılıkarından kaynaklanmaktadır. Makaledeki yöntemler daha yüksek doğruluk odaklı ve hesaplama maliyeti yüksek çözümler sunarken, YOLOv8l-seg modeli **daha hızlı, daha hafif ve gerçek zamanlı çalışmaya uygun** bir yapı sunmaktadır.

Ek Çalışma: Gerçek Dünya Koordinatları ile Yabancı Ot Tespiti (WeedyRice Veri Seti)

Bu çalışmada, WeedsGalore veri seti üzerinde gerçekleştirilen analizlerde, görüntülerin doğrudan kullanılabilir GPS (lat/lon) bilgisi içermemesi nedeniyle konumlandırma işlemleri yalnızca görüntü içi (lokal) koordinatlar üzerinden yapılmıştır. Bu yaklaşım, belirli bir ölçüde alan hesaplama ve göreli konum analizi için yeterli olsa da, gerçek dünya uygulamalarında ihtiyaç duyulan mutlak konum bilgisini üretme konusunda sınırlı kalmaktadır.

Bu sınırlamayı aşmak ve modeli gerçek dünya koordinatları ile değerlendirebilmek amacıyla, ek bir çalışma olarak **"A dataset of aligned RGB and multispectral UAV imagery for semantic segmentation of weedy rice"** veri seti kullanılmıştır. Bu veri seti sayesinde, model çıktılarının yalnızca görüntü düzeyinde değil, doğrudan coğrafi referanslar üzerinden analiz edilmesi mümkün hale getirilmiştir.

Neden WeedyRice Veri Seti Tercih Edildi?

Bu veri setinin tercih edilmesindeki temel neden, görüntülerle birlikte doğrudan **GPS (enlem-boylam) ve yükseklik** bilgilerini içermesidir. Veri setinde her bir görüntüye ait konum bilgileri hem dosya isimlerine gömülü şekilde hem de ayrı metadata dosyaları içerisinde açık ve erişilebilir olarak sunulmaktadır. Bu yapı, model çıktılarının piksel koordinatlarından gerçek dünya koordinatlarına dönüştürülmesini doğrudan mümkün kılmaktadır.

Sonuç olarak, WeedyRice veri seti; bu projede hedeflenen **gerçek dünya koordinatlarına dayalı analiz** yaklaşımını mümkün kılması açısından, yapılan araştırma sonucunda en uygun veri kaynağı olarak değerlendirilmiştir.

Makalenin ve Veri Setinin Özeti

Bu ek çalışma kapsamında incelenen **"A dataset of aligned RGB and multispectral UAV imagery for semantic segmentation of weedy rice"** makalesi, UAV tabanlı görüntüler kullanılarak yabani pirinç (weedy rice) tespiti ve segmentasyonu amacıyla hazırlanmış güncel ve uygulamaya yönelik bir veri setini tanıtmaktadır. Çalışma, özellikle hassas tarım (precision agriculture) ve uzaktan algılama tabanlı analizler için güçlü bir veri altyapısı sunmayı hedeflemektedir.

Veri seti, toplamda **734 adet yüksek çözünürlüklü RGB görüntü** ve bu görüntülerle piksel seviyesinde hizalı multispektral bantları (Green, Red, Red Edge ve Near-Infrared) içermektedir. Tüm veriler UAV (DJI Mavic 3 Multispectral) ile gerçek tarla koşullarında, Vietnam'ın Mekong Delta bölgesinde farklı zaman dilimlerinde ve farklı büyüme evrelerinde toplanmıştır. Bu sayede veri seti, farklı yabancı ot yoğunluklarını ve saha koşullarını içeren zengin bir dağılım sunmaktadır.

Veri setinin en önemli katkılarından biri, yalnızca görüntü ve segmentasyon maskeleri sunmakla kalmayıp, aynı zamanda her görüntü için **coğrafi referans (georeferenced) bilgileri** içermesidir. Görüntüler **WGS84 / UTM Zone 48N** koordinat sistemine göre konumlandırılmış olup, metadata dosyalarında her görüntüye ait **GPS koordinatları, çekim zamanı, yükseklik ve sensör bilgileri** detaylı şekilde yer almaktadır. Bu yapı sayesinde model çıktılarının doğrudan gerçek dünya koordinatları ile ilişkilendirilmesi mümkün hale gelmektedir.

Ayrıca veri setinde yer alan segmentasyon maskeleri, polygon tabanlı anotasyonlardan oluşturulmuş ve uzmanlar tarafından doğrulanarak yüksek kaliteye getirilmiştir. Maskeler **binary yapıdadır (yabani pirinç – arka plan)** ve piksel seviyesinde hassas ayrım yapmaya imkân tanımaktadır. Bununla birlikte, RGB görüntüler ile multispektral bantların tamamen hizalı olması, farklı veri türlerinin birlikte kullanılmasına olanak sağlayarak multimodal model geliştirme açısından önemli bir avantaj sunmaktadır.

Genel olarak değerlendirildiğinde bu veri seti, yalnızca görüntü tabanlı analizler için değil, aynı zamanda **konum tabanlı (geospatial) uygulamalar**, **multispektral veri füzyonu** ve **gerçek saha senaryolarına uygun model geliştirme** süreçleri için iyi bir kaynak olarak öne çıkmaktadır.

DeepLabv3 ve YOLO Modellerinin Karşılaştırılması ve Seçilen Nihai Mimari

Bu veri setinin yapısı incelendiğinde, doğrudan piksel seviyesinde hizalı RGB görüntüler, multispektral bantlar ve **binary segmentasyon maskeleri** sunduğu görülmektedir. Bu yapı, problemi klasik nesne tespiti yerine doğrudan bir **semantic segmentation** problemi olarak ele almayı gerektirmektedir.

Bu kapsamda, çalışmada yalnızca farklı bir model mimarisini değerlendirmek amacıyla değil, aynı zamanda veri setinin doğasına daha uygun bir yaklaşım benimsemek adına YOLO tabanlı segmentasyon modelleri yerine **DeepLabv3+** modeli tercih edilmiştir. Yapılan ön denemelerde YOLO'nun segmentasyon sürümleri de test edilmiş, ancak veri setinin yoğun, iç içe geçmiş ve ince sınırlar içeren bitki yapısı nedeniyle istenilen başarı seviyesine ulaşılamamıştır.

Ayrıca veri setinin **piksel bazlı (semantic) etiketleme yapısına sahip olması**, YOLO'nun tek aşamalı ve nesne odaklı yaklaşımıyla tam olarak örtüşmemektedir. YOLO erken evrelerde başarılı olmakla birlikte, geç evrelerdeki alan ölçümlerinde semantik modeller kadar verimli olamamıştır, bu veri setinde yer alan karmaşık ve sürekli yapıdaki bitki örtüsü için yeterli hassasiyeti sağlayamamaktadır.

Buna karşılık, **DeepLabv3+** gibi semantik segmentasyon odaklı mimariler, piksel seviyesinde daha hassas ayrım yapabilme yetenekleri sayesinde bu veri seti üzerinde daha başarılı sonuçlar vermiştir. Bu doğrultuda, hem farklı bir model yaklaşımını değerlendirmek hem de veri setinin yapısına daha uygun bir çözüm elde etmek amacıyla çalışmalar DeepLabv3+ modeli üzerinden sürdürülmüştür.

Veri Hazırlama ve Ön İşleme

Bu ek çalışmada kullanılan WeedyRice veri seti, doğrudan **RGB görüntüler ve binary segmentasyon maskeleri** içerdiği için veri hazırlama süreci daha sade ve kontrollü bir şekilde yürütülmüştür. Veri setindeki RGB görüntüler doğrudan kullanılmış, maskeler ise yabani pirinç (weedy rice) ve arka plan olacak şekilde **ikili (binary) formata** dönüştürülmüştür.

Veri setinin kendi içerisinde sunduğu train, validation ve test ayrımına sadık kalınmıştır**.**

Ayrıca veri setinde bulunan maskeler üzerinde küçük gürültüleri temizlemek ve daha stabil öğrenme sağlamak amacıyla morfolojik işlemler ve minimum alan filtreleme gibi ön işlemler uygulanmıştır. Bu sayede modelin çok küçük ve anlamsız bölgeleri öğrenmesi engellenerek daha anlamlı segmentasyon çıktıları elde edilmiştir.

Veri Artırma (Data Augmentation) Tercihleri

Veri setinde: yatay ve dikey çevirme (flip), döndürme (rotation), parlaklık ve kontrast değişimleri gibi temel augmentasyonlar uygulanmıştır.

Seçilen DeepLabv3+ Modelinden Elde Edilen Sonuçlar

Test Sonuçları:

- **IoU:** 0.77 **Dice:** 0.86 **Precision:** 0.86 **Recall:** 0.87

Bu sonuçlar, modelin hem segmentasyon doğruluğu hem de yabani pirinç bölgelerini yakalama başarısı açısından kabuledilebilir **bir performans** sergilediğini göstermektedir.

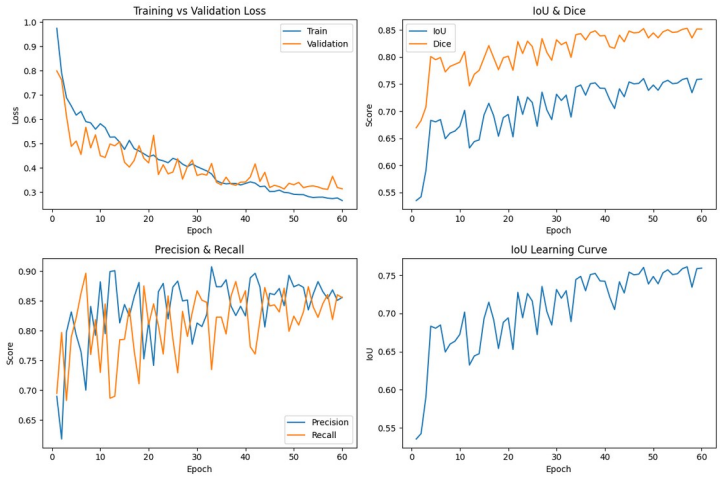

Görsel 5: Eğitim grafikleri.

Test Sonuçları ve Genel Başarı

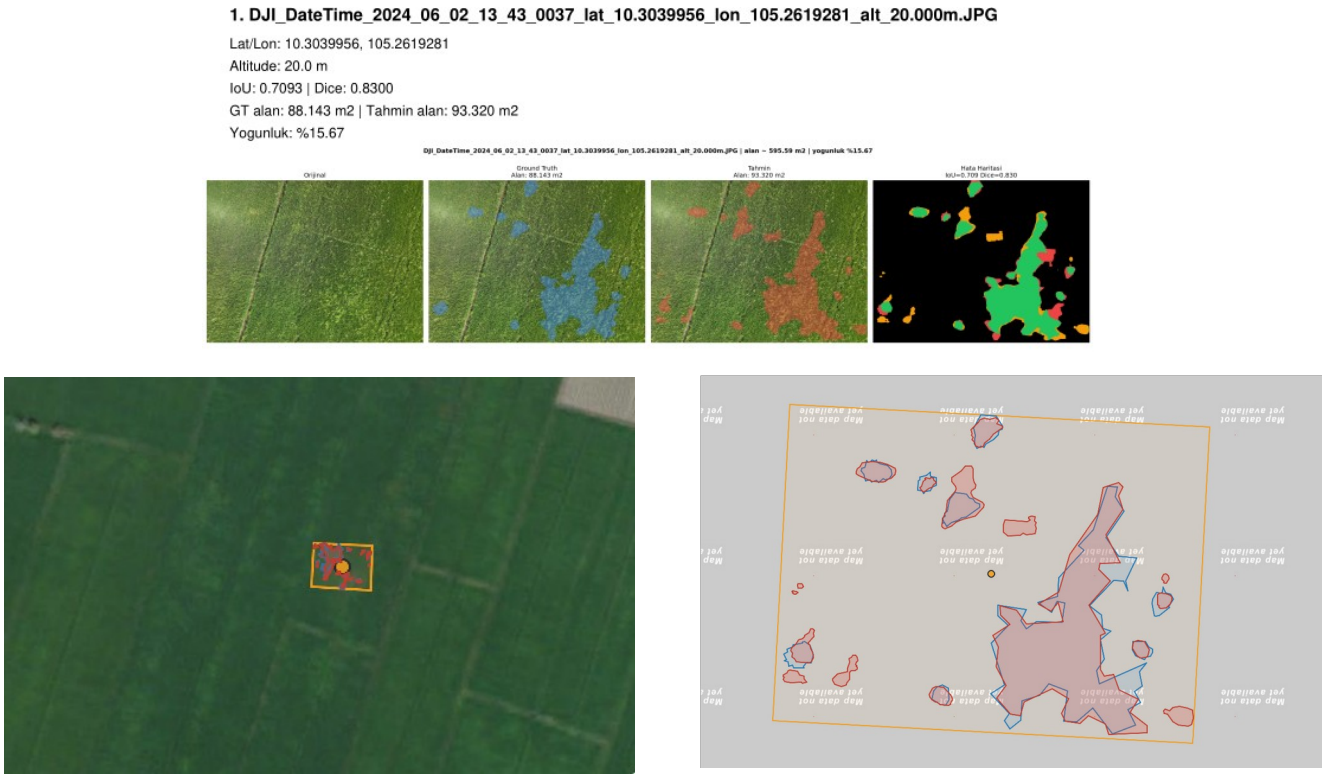

Görsel 62: Önrek test görseli sonuçları(segmentasyon ve haritada konumladırılması)

Görsel 6: Genel test özeti

Genel değerlendirme

Proje, WeedyRice veri setindeki RGB görüntüleri ve metadata dosyasındaki GPS verilerini alıp, DeepLabV3+ modelini kullanarak entegre bir sistem sunmuştur.

- **Gerçek Coğrafi Referanslama (Georeferencing):** Bu çalışmanın en büyük artısı, piksel bazlı tespitlerin gerçek dünya koordinatlarına (WGS84 / Enlem-Boylam) çevrilebilmesidir. Drone uçuş yüksekliği, kamera sensör boyutu ve odak uzaklığı kullanılarak her görüntünün izdüşümü hesaplanmış ve tespitler harita üzerinde gerçekçi bir şekilde konumlandırılmıştır.
- **Semantik Segmentasyonun Avantajı:** WeedsGalore'da kullanılan YOLO modelinin yarattığı aşırı parçalama (over-segmentation) hatası, bu çalışmada DeepLabV3+ kullanılarak çözülmüştür. İç içe geçmiş ot kümeleri (patch) tek bir anlamlı bölge olarak maskelenmiş, böylece alan hesabı (m2) çok daha isabetli hale gelmiştir.

Zor Örnekler İçin Hata Analizi ve Metrik Yorumlama

pirinç ve yabancı otu birbirine son derece benzediği bu özel senaryoda, modelin zorlandığı temel nokta gölge ve yaprak örtüşmeleridir (canopy overlap). DeepLabV3+, genel "yabancı ot alanını" tahmin etmede oldukça stabil kalsa da, bitki yoğunluğunun %40'ları aştığı parsellerde küçük ayrık bitkileri büyük kümelerin içine dahil etme eğilimindedir. Modelin ürettiği Hata Haritalarında (Turuncu=Yanlış Pozitif, Kırmızı=Yanlış Negatif) görüldüğü üzere, model genelde bitki sınırlarından ziyade bitkilerin tam orta kısımlarında başarılıdır. Kenar kısımlar poligon toleransından dolayı hata payı içermektedir.

Sonuç olarak

Bu ek çalışmada hedeflenen WeedyRice yabancı otlarının tespiti ve alan bazlı yoğunluk analizleri, DeepLabV3+ semantik modelinin kullanılmasıyla başarılı bir şekilde gerçekleştirilmiştir.

Daha da önemlisi, tespit edilen piksellerin sadece lokal görüntü düzleminde kalmayıp, drone metadata'sı kullanılarak kameranın izdüşümleriyle WGS84 oturtulmasıdır. Bu coğrafi verilerin interaktif bir HTML haritasına dönüştürülmesi, ikinci kısımda istenen sonucu alınamsını sağlamıştır. Nesne sayımının bu veri seti ve model üstüdne uyun olammasından dolayı sayım yerine "toplam kaplanan alan (m2)" ve "yabancı ot yoğunluk yüzdesi (%)" odaklı geliştirldi.

Yararlanılan Kaynaklar

1. Celikkan, E., Kunzmann, T., Yeskaliyev, Y., Itzerott, S., Klein, N., Herold, M., *WeedsGalore: A Multispectral and Multitemporal UAV-based Dataset for Crop and Weed Segmentation in Agricultural Maize Fields*, Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision (WACV), 2025.
2. A dataset of aligned RGB and multispectral UAV imagery for semantic segmentation of weedy rice Van-Hoa Nguyen, Cong-Doan Le, Minh-Tuyen Truong, Mai-Phung Thi Bui, Thanh-Phong Le, 2025
3. WeedsGalore Veri Seti ve Kod Deposu, https://github.com/GFZ/weedsgalore
4. Weedsrice Veri Seti, https://data.mendeley.com/datasets/vt4s83pxx6/1
5. WeedsGalore Makalesi (ArXiv), https://arxiv.org/abs/2502.13103
6. Weedy Rice Makalesi, https://www.sciencedirect.com/science/article/pii/S2352340925009588
7. WeedMap dataset, https://projects.asl.ethz.ch/datasets/doku.php?id=weedmap:remotesensing2018weedmap
8. PhenoBench dataset, https://www.phenobench.org/
9. CoFly-WeedDB dataset, https://data.mendeley.com/datasets/8g6r2b8p6k
10. Weedy Rice Dataset, https://data.mendeley.com/datasets/8w7p7j3x9r
11. Ultralytics YOLO, https://docs.ultralytics.com/
12. Google Colab, https://colab.research.google.com/
13. ChatGPT, https://chat.openai.com/
14. Google Gemini, https://gemini.google.com/
15. Kimi AI, https://kimi.moonshot.cn/